Metodologia per a l'Estudi de Col·lisions Culturals en Models de Llenguatge: El cas "Coca Is Not Cocaine"

Xavier Vinaixa Roselló
Sorensen AI, Barcelona

4 de maig de 2026

Resum

Aquest document detalla la metodologia experimental utilitzada per quantificar el biaix cultural i la col·lisió lèxica en models de llenguatge (LLM). L'enfocament es basa en l'extracció d'embeddings contextualitzats de conceptes culturals catalans inserits en diversos marcs oraculars i la seva comparació amb punts de referència (anchors) en un espai latent normalitzat.

1 Disseny del Corpus i Punts de Referència

L'experiment es fonamenta en un conjunt de dades curat de 56 conceptes culturals catalans (com ara *gegant, casteller, correfoc, panellet* o *coca*). Aquests conceptes han estat seleccionats per la seva naturalesa polièsmica o la seva absència de traducció directa unívoca a l'anglès que mantingui la càrrega cultural original.

Per mesurar la posició relativa d'aquests conceptes en l'espai latent, hem definit tres grups de punts de referència o *anchors*:

1. **Anchors Anglo**: 22 termes que defineixen un espai semàntic marcadament anglès o global (ex: *giant, dragon, knight*).
2. **Anchors Catalans**: 23 termes que defineixen el context institucional i cultural local (ex: *ajuntament, festa, plaça*).
3. **Anchors de Soroll (Noise)**: 13 termes específicament seleccionats per testar la col·lisió lèxica de la paraula *coca* (ex: *cocaine, Coca-Cola, soda*).

2 Models i Extracció de Representacions

Hem analitzat 11 models de llenguatge de pesos oberts, que abasten tres famílies principals (Gemma, Qwen, Mistral/DeepSeek) i una família de control natiu (Salamandra/ALIA del Barcelona Supercomputing Center). L'escala dels models varia des d'1,5B fins a 67B de paràmetres.

Per a cada parella (concepte, model), el procés d'extracció segueix els següents passos:

- **Selecció de Capa**: S'utilitza una capa intermèdia profunda (identificada prèviament com la que millor separa els clústers en proves de control).
- **Contextualització**: El concepte s'insereix en quatre marcs oraculars (*frames*):
  - `bare`: El lema sol, sense context.
  - `anglo_en`: El concepte inserit en una frase narrativa en anglès.
  - `catalan_frame`: El concepte inserit en una frase de festa major en català.

  - `catalan_neutral`: Una oració simple i informativa en català.

- **Agregació**: S'extreuen els estats ocults (*hidden states*) dels sub-tokens que formen el concepte i s'aplica una mitjana aritmètica (*mean-pooling*).
- **Normalització**: El vector resultant s'escala mitjançant normalització L_2 per permetre comparacions de similitud de cosinus.

3 Mètriques d'Anàlisi

La metodologia proposa dues mètriques principals per avaluar la deriva cultural:

3.1 Ràtio de Biaix (Bias Ratio)

Es calcula la distància de cosinus mitjana del concepte c respecte als conjunts d'anchors anglo (A) i catalans (C):

$$Bias_Ratio(c) = \frac{\overline{sim}(c, A)}{\overline{sim}(c, A) + \overline{sim}(c, C)} \tag{1}$$

On $\overline{sim}$ representa la mitjana de la similitud de cosinus. Un valor proper a 1 indica una atracció semàntica total cap al domini anglès.

3.2 Fracció de Proximitat Catalana (Top-10 Catalan Fraction)

Aquesta mètrica mesura la densitat del veïnatge immediat. S'identifiquen els 10 punts de referència més propers al concepte en l'espai latent i es calcula quina fracció d'aquests pertanyen al clúster català.

3.3 Validació de Col·lisió (Noise Hit Test)

Específicament per al concepte *coca*, comptem quants dels 10 veïns més propers pertanyen al clúster de soroll (*noise*). Aquest test permet identificar empíricament si el model està cometent un error de col·lisió lèxica (F1) o una deriva narrativa (F2).

4 Control i Reproduïabilitat

L'ús de la família Salamandra/ALIA actua com a control causal. En mantenir el *pipeline* constant però variar la dieta de dades de preentrenament, la metodologia permet distingir si les fallades representacionals s'originen en el mix de dades o en l'arquitectura de l'extractor d'embeddings.